

Министерство образования и науки Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Отчет по лабораторной работе № 4 **«Создание рекомендательной модели»** по курсу "Методы машинного обучения"

> Исполнитель: Студент группы ИУ5-22М Желанкина А.С. 22.04.2021

Задание лабораторной работы

Выбрать произвольный набор данных (датасет), предназначенный для построения рекомендательных моделей.

Опираясь на материалы лекции, сформировать рекомендации для одного пользователя (объекта) двумя произвольными способами.

Сравнить полученные рекомендации (если это возможно, то с применением метрик).

Описание датасета

Буккроссинг - это процесс выпуска книг «в дикую природу» для постороннего человека или посредством «контролируемого выпуска» другому участнику BookCrossing и отслеживание того, куда они попадают, с помощью журнальных записей со всего мира.

Экранные формы с текстом программы и примерами её выполнения

```
[ ] import numpy as np
                 import pandas as pd
                 import seaborn as sns
                 import matplotlib.pyplot as plt
                 import seaborn as sns
                 import warnings
                 import os
                 from tqdm import tqdm
                 from gensim.models import Word2Vec
                 import random
                 from surprise.accuracy import rmse
                 from sklearn.metrics.pairwise import cosine_similarity, euclidean_distances, manhattan_distances
                 from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer
                 from google.colab import drive
                  warnings.filterwarnings("ignore")
                 %matplotlib inline
                  sns.set(style="ticks")
  [ ] drive.mount("/content/gdrive", force_remount=True)
                 Mounted at /content/gdrive
[ ] users = pd.read_csv('/content/gdrive/My Drive/BX-Users.csv',
                                                      encoding = 'ISO-8859-1')
[ ] books = pd.read_csv('/content/gdrive/My Drive/BX-Books.csv', error_bad_lines=False, delimiter=';',
                                                      encoding = 'ISO-8859-1')
          b'Skipping line 6452: expected 8 fields, saw 9\nSkipping line 43667: expected 8 fields, saw 10\nSkipping line 51751: expected 8 fields, saw 9\n'
b'Skipping line 92038: expected 8 fields, saw 9\nSkipping line 104319: expected 8 fields, saw 9\nSkipping line 121768: expected 8 fields, saw 9\nSkipping line 144058: expected 8 fields, saw 9\nSkipping line 157128: expected 8 fields, saw 9\nSkipping line 209388: expected 8 fields, saw 9\nSkipping line 220938: expect
[ ] ratings = pd.read_csv('/content/gdrive/My Drive/BX-Book-Ratings.csv',
                                                      error_bad_lines=False, delimiter=';',
encoding = 'ISO-8859-1')
[ ] print("USERS: ", users.shape, users.columns)
print("BOOKS: ", books.shape, books.columns)
print("RATINGS: ", ratings.shape, ratings.columns)
```

```
USERS: (278858, 3) Index(['User-ID', 'Location', 'Age'], dtype='object')
BOOKS: (271360, 8) Index(['ISBN', 'Book-Title', 'Book-Author', 'Year-Of-Publication', 'Publisher',
                   'Image-URL-S', 'Image-URL-M', 'Image-URL-L'],
                 dtype='object')
        RATINGS: (1149780, 3) Index(['User-ID', 'ISBN', 'Book-Rating'], dtype='object')
 [ ] data = pd.merge(ratings, users, on='User-ID', how='inner')
        data = pd.merge(data, books, on='ISBN', how='inner')
        print("ALL DATA", data.shape, data.columns)
        ALL DATA (1031136, 12) Index(['User-ID', 'ISBN', 'Book-Rating', 'Location', 'Age', 'Book-Title',
                   'Book-Author', 'Year-Of-Publication', 'Publisher', 'Image-URL-S', 'Image-URL-M', 'Image-URL-L'],
                 dtype='object')
 [ ] data.head()
                                                              Book-
                                                                         Year-Of-
                                    Location Age Title
Γ1
                                                                                  Publisher
                                                                                                                                Image-URL-S
                                                       Flesh
                                                                                    Ballantine Rooks http://images.amazon.com/images/P/034545104X.0... http://images.amazon.com/images/P/034545104X.0...
     0 276725 034545104X
                                  0 texas, usa
                                                               Rose
                                                       Novel
                                      cincinnati.
                                                      Tones:
                                                                                    Ballantine Books http://images.amazon.com/images/P/034545104X.0... http://images.amazon.com/images/P/034545104X.0...
         2313 034545104X
                                                23.0
                                                                             2002
                                       ohio, usa
                                                       Novel
                                                       Flesh
                                       strafford.
                                                                                    Ballantine Rooks http://images.amazon.com/images/P/034545104X.0... http://images.amazon.em/images/P/034545104X.0...
                                                      Tones:
          6543 034545104X
                                      missouri,
                                                               Rose
                                           usa
                                                       Novel
                                                                                   Ballantine Books http://images.amazon.com/images/P/034545104X.0... http://images.amazon.com/images/P/034545104X.0...
                                        county.
                                                      Tones:
          8680 034545104X
                                                                             2002
                                           usa
                                                       Novel
                                     beaverton
                                                                                   Ballantine Books http://images.amazon.com/images/P/034545104X.0... http://images.amazon.com/images/P/034545104X.0...
                                                      Tones:
     4 10314 034545104X
                                       oregon, NaN
```

[] data.info()

<class 'pandas.core.frame.DataFrame'> Int64Index: 1031136 entries, 0 to 1031135 Data columns (total 12 columns):

usa

memory usage: 102.3+ MB

#	Column	Non-Null Count	Dtype				
0	User-ID	1031136 non-null	int64				
1	ISBN	1031136 non-null	object				
2	Book-Rating	1031136 non-null	int64				
3	Location	1031136 non-null	object				
4	Age	753301 non-null	float64				
5	Book-Title	1031136 non-null	object				
6	Book-Author	1031135 non-null	object				
7	Year-Of-Publication	1031136 non-null	object				
8	Publisher	1031134 non-null	object				
9	Image-URL-S	1031136 non-null	object				
10	Image-URL-M	1031136 non-null	object				
11	Image-URL-L 1031132 non-null object						
<pre>dtypes: float64(1), int64(2), object(9)</pre>							

Rose

```
[ ] print('Number of books: ', data['ISBN'].nunique())
    print('Number of users: ',data['User-ID'].nunique())
```

```
Number of users: 92106
[ ] median = data["Age"].median()
   std = data["Age"].std()
    is_null = data["Age"].isnull().sum()
    rand_age = np.random.randint(median - std, median + std, size = is_null)
    age_slice = data["Age"].copy()
    age_slice[pd.isnull(age_slice)] = rand_age
    data["Age"] = age_slice
    data["Age"] = data["Age"].astype(int)
[ ] data['Book-Rating'] = data['Book-Rating'].replace(0, None)
[ ] data[['Book-Author', 'Publisher']] = data[['Book-Author', 'Publisher']].fillna('Unknown')
[ ] data = data.dropna(axis=0, how='any')
    data = data.drop(['Image-URL-S', 'Image-URL-M', 'Image-URL-L'], axis=1)
[ ] data.isnull().sum()
    User-ID
    ISBN
                            0
    Book-Rating
    Location
                            0
    Age
    Book-Title
                            0
    Book-Author
                            0
    Year-Of-Publication
                            0
                            0
    Publisher
    dtype: int64
[ ] data['Country'] = data['Location'].apply(lambda row: str(row).split(',')[-1])
    data = data.drop('Location', axis=1)
    data['Country'].head()
    0
          usa
    1
         usa
    2
          usa
    3
          usa
    4
    Name: Country, dtype: object
```

Number of books: 270151

```
[ ] data['Year-Of-Publication'] = pd.to_numeric(data['Year-Of-Publication'])
[ ] df = data
[ ] df = df[df['Book-Rating'] >= 6]
    df.groupby('ISBN')['User-ID'].count().describe()
    count 228988.000000
                3.728409
    mean
               12.416574
    std
                 1.000000
    min
                 1.000000
    25%
                1.000000
    50%
    75%
                 3.000000
          1206.000000
    max
    Name: User-ID, dtype: float64
[ ] title = df['Book-Title'].values
    author = df['Book-Author'].values
    publisher = df['Publisher'].values
    ISBN = df['ISBN'].values
    rating = df['Book-Rating'].values
[ ] %%time
    tfidfv = TfidfVectorizer()
    title_matrix = tfidfv.fit_transform(title)
    author_matrix = tfidfv.fit_transform(author)
    publisher_matrix = tfidfv.fit_transform(publisher)
    ISBN_matrix = tfidfv.fit_transform(ISBN)
    CPU times: user 17.3 s, sys: 167 ms, total: 17.5 s
    Wall time: 17.5 s
```

Фильтрация на основе содержания

```
[ ] class SimpleKNNRecommender:
        def __init__(self, X_matrix, X_ids, X_title, X_overview):
            Входные параметры:
            X matrix - обучающая выборка (матрица объект-признак)
            X_ids - массив идентификаторов объектов
            X_title - массив названий объектов
            X_overview - массив описаний объектов
            #Сохраняем параметры в переменных объекта
            self._X_matrix = X_matrix
            self.df = pd.DataFrame(
                 {'id': pd.Series(X_ids, dtype='int'),
                 'title': pd.Series(X_title, dtype='str'),
                 'overview': pd.Series(X_overview, dtype='str'),
                 'dist': pd.Series([], dtype='float')})
        def recommend_for_single_object(self, K: int, \
                     X_matrix_object, cos_flag = True, manh_flag = False):
            Метод формирования рекомендаций для одного объекта.
            Входные параметры:
            К - количество рекомендуемых соседей
            X_matrix_object - строка матрицы объект-признак, соответствующая объекту
            cos_flag - флаг вычисления косинусного расстояния
            manh_flag - флаг вычисления манхэттэнского расстояния
            Возвращаемое значение: К найденных соседей
            scale = 1000000
            # Вычисляем косинусную близость
            if cos_flag:
                dist = cosine_similarity(self._X_matrix, X_matrix_object)
                self.df['dist'] = dist * scale
                res = self.df.sort_values(by='dist', ascending=False)
                # Не учитываем рекомендации с единичным расстоянием,
                # так как это искомый объект
                res = res[res['dist'] < scale]
             else:
                if manh_flag:
                     dist = manhattan_distances(self._X_matrix, X_matrix_object)
                     dist = euclidean_distances(self._X_matrix, X_matrix_object)
                 self.df['dist'] = dist * scale
                 res = self.df.sort values(by='dist', ascending=True)
```

```
# Не учитываем рекомендации с единичным расстоянием,
# так как это искомый объект
res = res[res['dist'] > 0.0]

# Оставляем К первых рекомендаций
res = res.head(K)
return res

[] author_ind = 54
author[author_ind]

'Nicholas Sparks'

[] sparks_matrix = author_matrix[author_ind]

[] skr1 = SimpleKNNRecommender(author_matrix, rating, title, author)
rec1 = skr1.recommend_for_single_object(15, sparks_matrix)
rec1
```

		id	title	overview	dist
	442981	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	679127.939310
[]	442978	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	679127.939310
	442977	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	679127.939310
	328753	6	The Discovery of Animal Behaviour	John Sparks	617606.995898
	623204	9	The Last of the Cockleshell Heroes: A World Wa	William Sparks	570039.764169
	822969	7	The Next Archaeology Workbook	Nicholas David	526087.742446
	516949	9	Cook: The Extraordinary Voyages of Captain Jam	Nicholas Thomas	496039.823116
	589733	10	The Elephant Man	Christine Sparks	485967.020337
	852180	7	Elephant Man	Christine Sparks	485967.020337
	589732	10	The Elephant Man	Christine Sparks	485967.020337
	281592	7	Veronica	Nicholas Christopher	475879.754871
	390227	9	Veronica: A Novel	Nicholas Christopher	475879.754871

```
[ ] rec2 = skr1.recommend_for_single_object(15, sparks_matrix, cos_flag = False)
    rec2
```

	id	title	overview	dist
442981	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	801089.334207
442978	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	801089.334207
442976	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	801089.334207
442977	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	801089.334207
442979	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	801089.334207
442980	10	A Lifelong Passion: Nicholas and Alexandra	Nicholas	801089.334207
328753	6	The Discovery of Animal Behaviour	John Sparks	874520.444703
623204	9	The Last of the Cockleshell Heroes: A World Wa	William Sparks	927318.969752
822969	7	The Next Archaeology Workbook	Nicholas David	973562.794640
456102	8	The Sensuous Woman	J	1000000.000000
748786	8	The White Road Westward	B.B.	1000000.000000
748787	8	The Autumn Road to the Isles	B.B.	1000000.000000
781072	8	Cuentos de Encuentros y Desencuentros Amorosos	V. V. A. A.	1000000.000000

Метод на основе сингулярного разложения

Г→

```
[ ] def create_utility_matrix(data):
    itemField = 'Book-Title'
    userField = 'User-ID'
    valueField = 'Book-Rating'

    userList = data[userField].tolist()
    itemList = data[itemField].tolist()
    valueList = data[valueField].tolist()

    users = list(set(userList))
    items = list(set(itemList))

    users_index = {users[i]: i for i in range(len(users))}
    pd_dict = {item: [0.0 for i in range(len(users))] for item in items}

    for i in range(0,data.shape[0]):
        item = itemList[i]
        user = userList[i]
        value = valueList[i]
```

```
pd_dict[item][users_index[user]] = value
        X = pd.DataFrame(pd_dict)
        X.index = users
        itemcols = list(X.columns)
        items_index = {itemcols[i]: i for i in range(len(itemcols))}
         return X, users_index, items_index
[ ] mini_df = df[0:500]
[ ] %%time
    user_item_matrix, users_index, items_index = create_utility_matrix(mini_df)
    CPU times: user 3.44 ms, sys: 0 ns, total: 3.44 ms
    Wall time: 3.16 ms
[ ] user_item_matrix
[ ] user_item_matrix__test = user_item_matrix.iloc[469]
     user_item_matrix__train = user_item_matrix.iloc[:470]
[ ] %%time
    U, S, VT = np.linalg.svd(user_item_matrix__train.T)
    V = VT.T
    CPU times: user 8.76 ms, sys: 7.17 ms, total: 15.9 ms
    Wall time: 28.9 ms
[ ] Sigma = np.diag(S)
[ ] r=3
    Ur = U[:, :r]
    Sr = Sigma[:r, :r]
    Vr = V[:, :r]
[ ] test_user = np.mat(user_item_matrix__test.values)
    test_user.shape, test_user
    ((1, 7), matrix([[8., 0., 0., 0., 0., 0., 0.]]))
```

```
[ ] tmp = test_user * Ur * np.linalg.inv(Sr)
    matrix([[-0.013692 , 0.07842731, 0.02007541]])
[ ] test_user_result = np.array([tmp[0,0], tmp[0,1], tmp[0,2]])
    test_user_result
    array([-0.013692 , 0.07842731, 0.02007541])
[ ] # Вычисляем косинусную близость между текущим пользователем
    # и остальными пользователями
    cos_sim = cosine_similarity(Vr, test_user_result.reshape(1, -1))
    cos_sim[:10]
    array([[-0.05145611],
           [-0.02704594],
           [ 1.
           [-0.02704594],
           [ 0.87936934],
           [-0.02704594],
[ ] # Преобразуем размерность массива
    cos_sim_list = cos_sim.reshape(-1, cos_sim.shape[0])[0]
    cos_sim_list[:10]
    array([-0.05145611, -0.02704594, 1. , -0.02704594, 0.87936934,
           -0.02704594, 1. , -0.02704594, 1. , 0.87936934])
[ ] # Находим наиболее близкого пользователя
    recommended_user_id = np.argsort(-cos_sim_list)[0]
    recommended_user_id
    254
[ ] # Получение названия фильма
    userId_list = list(user_item_matrix.columns)
    def book name by user(ind):
        try:
            userId = userId_list[ind]
            flt_links = mini_df[mini_df['User-ID'] == userId]
            #tmdbId = int(flt_links['tmdbId'].values[0])
            #md_links = df_md[df_md['id'] == tmdbId]
            res = mini_df['Book-Title'].values[0]
            return res
```

```
except:
    return ''

i=1
for idx, item in enumerate(np.ndarray.flatten(np.array(test_user))):
    if item > 0:
        book_title = book_name_by_user(idx)
        print('{} - {} - {}'.format(idx, book_title, item))

0 - Flesh Tones: A Novel - 8.0
```