



**Министерство образования и науки Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

ФАКУЛЬТЕТ

ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА

СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

**Отчет по лабораторной работе № 5
«Предобработка текста»
по курсу “Методы машинного обучения”**

**Исполнитель:
Студент группы ИУ5-22М
Желанкина А.С.
15.05.2021**

Москва, 2021

Задание лабораторной работы

Для произвольного предложения или текста решите следующие задачи:

- Токенизация.
- Частеречная разметка.
- Лемматизация.
- Выделение (распознавание) именованных сущностей.
- Разбор предложения. применением метрик).

Экранные формы с текстом программы и примерами её выполнения

sentence = 'В 1856 году Толстой задумал повесть о возвращении декабриста из ссылки, но со временем всё больше отклонялся от первоначального замысла.'

токенизация

```
[2] from spacy.lang.ru import Russian
import spacy
```

```
[14] nlp = spacy.load('ru_core_news_sm')
      spacy_text = nlp(sentence)
      spacy_text
```

В 1856 году Толстой задумал повесть о возвращении декабриста из ссылки, но со временем всё больше отклонялся от первоначального замысла.

частеречная разметка

```
for token in spacy_text:
    print('{text} - {pos} - {dep}'.format(token.text, token.pos_, token.dep_))
```

```
В - ADP - case
1856 - ADJ - amod
году - NOUN - obl
Толстой - PROPN - nsubj
задумал - VERB - ROOT
повесть - NOUN - obj
о - ADP - case
возвращении - NOUN - nmod
декабриста - NOUN - nmod
из - ADP - case
ссылки - NOUN - nmod
, - PUNCT - punct
но - CCONJ - cc
со - ADP - case
```

лемматизация

```
[16] for token in spacy_text:
      print(token, token.lemma, token.lemma_)
```

```
В 15939375860797385675 в
1856 17326095754085996097 1856
году 10808799184780049468 год
Толстой 4046050732273088858 толстой
задумал 5422917566303273817 задумать
повесть 9309007651273142624 повесть
о 7798573245933969025 о
возвращении 18002089832685878868 возвращение
декабриста 4099941688933638916 декабрист
из 12183146372738139588 из
ссылки 5640322796510443772 ссылка
, 2593208677638477497 ,
но 14653780147686393572 но
со 12039906729841018817 со
временем 14199711609533390218 время
всё 15417895030994739546 всё
```

выделение (распознавание) именованных сущностей

```
[17] for ent in spacy_text.ents:
      print(ent.text, ent.label_)
```

Толстой PER

```
[18] from spacy import displacy

displacy.render(spacy_text, style='ent', jupyter=True)
```

В 1856 году Толстой **PER** задумал повесть о возвращении декабриста из ссылки, но со временем всё больше отклонялся от

```
[19] print(spacy.explain("PER"))
```

Named person or family.

разбор предложения

```
[20] from spacy import displacy
```

```
displacy.render(spacy_text, style='dep', jupyter=True)
```

